


Wprowadzenie do lokalnych LLM z Ollama



Czym jest Sztuczna Inteligencja (AI)?

Sztuczna inteligencja to zbiór metod i systemów, które pozwalają komputerom wykonywać zadania wymagające zwykle ludzkiej inteligencji, takie jak analiza danych, rozumienie języka czy podejmowanie decyzji.



- **Machine Learning (Uczenie maszynowe)** — dziedzina sztucznej inteligencji, w której system uczy się na podstawie danych i przykładów, zamiast działać wyłącznie według wcześniej zaprogramowanych reguł. Pozwala wykrywać wzorce, przewidywać wyniki i automatycznie doskonalić swoje działanie.
- **Deep Learning (Głębokie uczenie)** — zaawansowana forma uczenia maszynowego oparta na wielowarstwowych sieciach neuronowych. Umożliwia analizę bardzo dużych ilości danych, rozpoznawanie obrazów, mowy czy języka naturalnego.
- **Generative AI (Generatywna sztuczna inteligencja)** — modele AI zdolne do tworzenia nowych treści na podstawie wzorców poznanych podczas treningu. Mogą generować tekst, obrazy, muzykę, dźwięk, wideo lub kod programistyczny.
- **LLM — Large Language Model (Duży model językowy)** — rodzaj generatywnej AI wyspecjalizowany w rozumieniu, analizie i tworzeniu tekstu w języku naturalnym. Modele LLM potrafią odpowiadać na pytania, prowadzić rozmowy, tłumaczyć teksty, podsumowywać informacje oraz generować kod.

Czym są LLM-y?

Duże modele językowe (LLM — Large Language Models) to zaawansowane systemy AI trenowane na ogromnych zbiorach danych tekstowych. Potrafią rozumieć język naturalny, analizować kontekst oraz generować spójne odpowiedzi, ponieważ przewidują najbardziej prawdopodobne kolejne tokeny na podstawie wcześniejszego kontekstu.



Najpopularniejsze modele LLM

- OpenAI — seria modeli GPT, np. GPT-4 i GPT-4o
- Meta — modele Llama 3
- Google — Gemini
- Anthropic — Claude
- Mistral AI — Mistral i Mixtral
- Alibaba Cloud — Qwen
- DeepSeek — DeepSeek LLM





Wybór modelu

- Parametry to wiedza zapisana w modelu — im więcej, tym model zdolniejszy, ale też cięższy w uruchomieniu. Jeden model może mieć kilka rozmiarów (np. 1B, 7B, 70B).
- **Dense (model gęsty)** — przy każdym pytaniu model używa całej swojej wiedzy jednocześnie. Proste i przewidywalne, ale kosztowne obliczeniowo.
- **MoE — Mixture of Experts (mieszanka ekspertów)** — model podzielony jest na wielu wyspecjalizowanych „ekspertów”. Przy każdym pytaniu budzi się tylko kilku z nich — tych, którzy są naprawdę potrzebni. Dzięki temu MoE może być mądry jak duży model, ale działać szybciej i wydajniej.

LLM lokalnie vs w chmurze

Lokalnie

- model działa na własnym komputerze lub serwerze

Zalety:

- większa prywatność
- większa kontrola
- możliwość pracy offline

Wady:

- większe wymagania sprzętowe
- trudniejsze utrzymanie.

Przykłady: **Ollama**, **LM Studio**

W chmurze

- model działa na serwerach dostawcy i korzystamy z niego przez internet

Zalety:

- szybkie wdrożenie
- łatwe skalowanie
- brak potrzeby własnej infrastruktury

Wady:

- mniejsza kontrola nad danymi
- zależność od internetu
- koszty użycia

Przykłady: **ChatGPT**, **Amazon Bedrock**, usługi modelowe AWS

Czym jest Ollama?

Ollama to proste narzędzie do uruchamiania modeli LLM lokalnie. Działa jak warstwa pośrednia, która upraszcza pobieranie modelu, jego uruchomienie i komunikację z nim przez lokalne API.



Instalacja Ollama

Download Ollama



macOS



Linux



Windows

```
irm https://ollama.com/install.ps1 | iex
```

paste this in PowerShell

or

Download for Windows

Requires Windows 10 or later



Alpaka

OLLAMA – Podstawy

[POBIERANIE I ZARZĄDZANIE]

`ollama pull <model>`

- pobiera model na dysk

`ollama list`

- wyświetla listę pobranych modeli

`ollama rm <model>`

- usuwa model z dysku

[URUCHAMIANIE]

`ollama run <model>`

- startuje interaktywny czat z modelem

`ollama stop <model>`

- wyłącza model i zwalnia pamięć RAM

`ollama serve`

- uruchamia serwer
(nie działa na Windows)

[PRZYDATNE FLAGI (przy uruchamianiu)]

`--verbose / -v`

- pokazuje statystyki szybkości i czasu

`--format json`

- wymusza odpowiedź tylko w formacie JSON

[KOMENDY W CZACIE]

`/? lub /help`

- wyświetla pomoc i listę komend

`/bye`

- wyjście z czatu i powrót do terminala

[SZYBKI WORKFLOW]

1. `ollama pull <model>`
2. `ollama run <model>`
3. (rozmawiasz z modelem)
4. `/bye`
5. `ollama stop <model>`



Ćwiczenie

Pierwsze kroki z Ollamą



Integracja Ollamy z Pythonem

Ollamę można łatwo połączyć z aplikacją napisaną w Pythonie za pomocą biblioteki **ollama**. Biblioteka ta pozwala wysyłać zapytania do modelu, odbierać odpowiedzi i integrować lokalny LLM bezpośrednio z własnym kodem.



Aplikacje

Integracja Ollamy z Pythonem pozwala tworzyć różne typy aplikacji opartych na lokalnych modelach językowych, takie jak chatboty z pamięcią rozmowy, systemy streszczające dokumenty, narzędzia do generowania danych w formacie JSON oraz aplikacje analizujące i zapisujące wyniki do plików.

Ćwiczenie

Używanie Ollamy w Pythonie



Dziękujemy za wspólne warsztaty!



Warsztaty przygotowali członkowie koła naukowego Alpaka:

- Jakub Mielcarek
- Jakub Szczerbiński
- Marta Machacka
- Alpaka Charlie Alpacino

